

Actor-Critic 与 A2C

先讲一个故事

你在学钢琴。你的老师有两种教法：

教法一 (REINFORCE)：弹完整首曲子，老师在最后评分——「总体 85 分」。这个信号能告诉你哪个音弹错了吗？不能。第 3 小节那个跑偏的和弦、第 12 小节的速度失控，全部淹没在「85 分」这一个数字里。回去你只能靠猜测去改进。

教法二 (Actor-Critic)：老师坐在旁边，每弹几个音就给一句评价——「这里太快」「这个和弦不对」「这段处理得很好」。即时反馈、精准定位，进步快得多。

但问题来了：如果老师在你弹了三个音之后，就认定「我已经摸透这个学生的水平了」，从此不再认真听，只是机械地说「还可以」……从那一刻起，你的练习就失去了有效反馈，进步彻底停止。

这就是朴素 Actor-Critic 失败的本质——不是方向错了，而是策略在没有熵保护的情况下过早坍缩成确定性策略，每局轨迹变得雷同；Critic 随即把这个很差的策略的价值函数拟合到几乎完美，优势信号归零，Actor 的梯度消失。

本章要解决的核心问题：**如何让 Critic 的学习速度始终与 Actor 的改进速度保持匹配？**

从 REINFORCE 到 Actor-Critic：为什么要替换回报

REINFORCE 的策略梯度估计量：

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^T \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot G_t \right]$$

其中 $G_t = \sum_{k=t}^T \gamma^{k-t} r_k$ 是第 t 步到回合结束的折扣累积奖励（Monte Carlo 回报）。

高方差的来源： G_t 依赖于 t 时刻之后所有未来步骤的随机动作与随机奖励。回合越长， G_t 的随机性越大，梯度估计的方差越高——靠「整首曲子最终得分」判断「第 3 小节第 2 拍指法对不对」，信噪比极低。

核心替换：用值函数 $V^{\pi}(s)$ 提供一个基准（baseline），把 G_t 替换为「比平均水平高多少」：

$$G_t \longrightarrow A^{\pi}(s_t, a_t) = Q^{\pi}(s_t, a_t) - V^{\pi}(s_t)$$

这就是**优势函数 (Advantage Function)**。 $A > 0$ 代表「这个动作比平均更好」； $A < 0$ 代表「比平均更差」。用 A 代替 G_t 的两个好处：(1) 减去了与动作无关的基准 V ，方差降低；(2) 只衡量相对好坏，信号更精准。

优势函数与 TD 误差

数学形式化

设智能体当前策略为 π_{θ} ，参数化价值函数为 $V_{\phi}(s)$ 。定义：

- **状态价值函数**： $V^{\pi}(s) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k} \mid s_t = s \right]$
- **动作价值函数**： $Q^{\pi}(s, a) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k} \mid s_t = s, a_t = a \right]$
- **优势函数**： $A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s)$

注意 $\mathbb{E}_{a \sim \pi}[A^\pi(s, a)] = 0$ ——优势函数的期望恒为零，这是它的归一化性质，保证「好动作」和「坏动作」正好对称分布在零两侧。

单步 TD 误差作为优势的近似

计算真实的 $Q^\pi(s, a)$ 需要完整的未来奖励序列。可行的近似：

$$Q^\pi(s_t, a_t) \approx r_t + \gamma V^\pi(s_{t+1}) \quad (\text{单步 bootstrap})$$

代入优势函数定义，得到**单步 TD 误差** (Temporal Difference error)：

$$\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)$$

翻译成成人话： δ_t 是「实际拿到的奖励 + 对未来的新预期」比「出发前的旧预期」多还是少。多 $\Rightarrow$ 这步动作比预期好（正优势）；少 $\Rightarrow$ 比预期差（负优势）。

偏差的来源： δ_t 用近似值函数 V_ϕ 替代了真实 V^π ，引入了函数逼近误差（偏差）。这是与 Monte Carlo 的本质权衡：**方差下降，但不再无偏。**

朴素 Actor-Critic 为什么失败

四个故障模式

最直接的实现：把 REINFORCE 的每回合更新改成每步在线更新，用 δ_t 代替 G_t 。这个想法正确，但有四个潜伏的致命问题：

1. Fault 1 ——单步 TD 优势，方差仍然偏高

δ_t 只看一步，受随机奖励和 V_ϕ 估计误差的双重噪声影响。当 V_ϕ 尚未收敛时， δ_t 的估计极不稳定，Actor 梯度信号噪声大。

2. Fault 2 ——两时间尺度条件被违反

Konda & Tsitsiklis (2003) 证明：Actor-Critic 的收敛性要求 Critic 的学习率 α_w 远大于 Actor 的学习率 α_θ ，即 $\alpha_\theta/\alpha_w \rightarrow 0$ 。朴素实现两者使用相同学习率，使得 Actor 在 Critic 尚未收敛时就开始更新，用错误的 V_ϕ 计算梯度方向。

3. Fault 3 ——无熵正则化，策略提前坍塌

没有熵 bonus，Actor 会迅速把概率堆在某个次优动作上，变为近确定性策略。此后即使 δ_t 偶尔非零，动作分布没有随机性，策略梯度也无法推动探索。

4. Fault 4 ——无梯度裁剪，参数可能爆炸

单步 $|\delta_t|$ 有时极大（初始化差的 V_ϕ ），造成巨大参数更新，使网络进入不可恢复的坏区域。

坍塌机制：优势归零 $\Rightarrow$ Actor 冻结

Fault 3 触发后，四个故障耦合形成自我强化的恶性循环：

无熵 $\Rightarrow \pi$ 快速确定化 $\Rightarrow$ 每个 episode 退化为完全相同的短轨迹
 $\Rightarrow V_\phi$ 迅速拟合这些轨迹 ($\delta_t \approx 0$) $\Rightarrow \nabla_\theta J \approx 0 \Rightarrow$ Actor 永远冻结。

这是一个**稳定但灾难性的固定点**：Critic 越「完美」，Actor 越没有改进动力；Actor 越不动，Critic 就越稳固。系统自我锁死，且这个锁死状态对所有随机种子几乎一致。

实验证据

图 1 展示了 5 个随机种子下朴素 Actor-Critic 在 CartPole-v1 上的表现：episode return 从第 ~ 20 轮起彻底钉死在 ≈ 9 (CartPole-v1 最大为 500)，500 轮训练毫无进展。5 条曲线几乎重叠，说明这不是随机性问题，而是 5 个 seed 全部落入了同一个坏固定点。




图 1: 朴素 Actor-Critic ($\alpha = 5 \times 10^{-3}$, 无熵, 无梯度裁剪) 在 CartPole-v1 上的 5 个随机种子: episode return 全程钉死在 ≈ 9 , CartPole-v1 最大回报为 500。

图 2 给出了坍缩机制的直接证据：朴素 AC 的均值 $|\text{advantage}|$ 在前 50 轮内从 ≈ 3.5 急速跌至 ≈ 0.1 ，此后全程贴近零轴，Actor 梯度信号彻底消失。与之对比，A2C 的 $|\text{advantage}|$ 呈现**钟形曲线**——随策略改进而持续上升（Critic 追不上），随接近收敛而平滑回落——这是在线学习系统的健康特征。

广义优势估计 (GAE)

偏差-方差权衡的数学框架

单步 TD 误差 δ_t 偏差高 (V_ϕ 不准时)；Monte Carlo 回报 $G_t - V(s_t)$ 方差高 (轨迹越长随机性越大)。能不能在两者之间找到可调的中间点？

Schulman et al. (2015) 提出**广义优势估计 (Generalized Advantage Estimation, GAE)**：

Fig 3. Advantage Collapse: $|\text{advantage}| \rightarrow 0$ Freezes the Actor




图 2: 每回合均值 $|\hat{A}_t|$ 的演化 (5 seeds, mean $\pm$ 1 std)。蓝色 (朴素 AC) 在前 50 轮内归零; 红色 (A2C) 维持非零信号, 钟形轮廓反映了 Critic 与 Actor 之间持续的「追赶」动态。

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}$$

其中每一项 $\delta_{t+l} = r_{t+l} + \gamma V(s_{t+l+1}) - V(s_{t+l})$ 是第 $t+l$ 步的 TD 误差, $\lambda \in [0, 1]$ 是插值参数。

推导: GAE 是 TD 误差的几何级数

展开 GAE 前 n 步:

$$\hat{A}_t^{(n)} = \sum_{l=0}^{n-1} (\gamma \lambda)^l \delta_{t+l} = \delta_t + \gamma \lambda \delta_{t+1} + (\gamma \lambda)^2 \delta_{t+2} + \dots$$

两个极端:

- $\lambda = 0$: $\hat{A}_t = \delta_t$ (单步 TD), 高偏差、低方差, 完全依赖 V_ϕ 的准确性;
- $\lambda = 1$: $(\gamma \lambda)^l = \gamma^l$, 对所有未来 TD 误差求和, 级数通过望远镜求和 (telescoping) 等价于

$$\hat{A}_t^{\lambda=1} = \sum_{l=0}^{T-t-1} \gamma^l \delta_{t+l} = \underbrace{\sum_{l=0}^{T-t-1} \gamma^l r_{t+l} - V(s_t)}_{G_t} + \gamma^{T-t} V(s_T) \approx G_t - V(s_t), \quad (\text{终态 } V(s_T) \approx 0)$$

即退化为 REINFORCE 的 baseline 优势, 低偏差、高方差。

λ	极端情形	偏差 / 方差
0	$\hat{A}_t = \delta_t$ (单步 TD)	高偏差, 低方差
1	$\hat{A}_t = G_t - V(s_t)$ (Monte Carlo)	低偏差, 高方差
$\lambda \in (0, 1)$	几何插值	可控权衡

为什么几何衰减合理？ 近期 TD 误差信噪比更高 (V_ϕ 对近期状态预测更准), 远期 TD 误差累积了更多随机性。用 $(\gamma\lambda)^l$ 赋予近期更大权重, 相当于对梯度估计做了隐式的指数平滑。

GAE 的实际使用

GAE 计算需要完整的 TD 误差序列, 因此要先完成一整局 rollout, 再从末态向前递推:

$$\hat{A}_{T-1} = \delta_{T-1}, \quad \hat{A}_t = \delta_t + \gamma\lambda \hat{A}_{t+1} \quad (t = T-2, \dots, 0)$$

对应的 **Critic 训练目标** (回报估计):

$$\hat{R}_t = \hat{A}_t + V_\phi(s_t)$$

λ 的实践选择: $\lambda = 0.95$ 是经验默认值, 在大多数连续控制和离散控制任务中工作良好 (Schulman et al. 2015, 2017)。

Advantage Actor-Critic (A2C): 四个修复

针对四个故障逐一修补

1. Fix 1 ——完整 episode rollout + GAE

收集完整一局轨迹后再计算所有时步的优势, 用 GAE ($\lambda = 0.95$) 替代单步 δ_t 。比单步 TD 方差低, 比 Monte Carlo 偏差低。

2. Fix 2 ——两时间尺度学习率

设 Critic 学习率 $\alpha_w = 10^{-3}$, Actor 学习率 $\alpha_\theta = 3 \times 10^{-4}$ ($\alpha_w/\alpha_\theta \approx 3$)。Critic 在每轮更新时比 Actor 学得更快, 确保 Actor 下次更新时能用上较准确的 V_ϕ 。

3. Fix 3 ——熵正则化

在 Actor 损失中加入策略熵惩罚项, 阻止策略过早坍缩为确定性分布:

$$L_{\text{actor}} = -\hat{A}_t \log \pi_\theta(a_t | s_t) - \beta \mathcal{H}[\pi_\theta(\cdot | s_t)], \quad \beta = 0.01$$

4. Fix 4 ——梯度裁剪

更新前对梯度做 max-norm 裁剪 (clip = 0.5), 防止单次更新步长过大造成参数爆炸。

完整算法流程

1. **Rollout (无梯度):** 用当前 π_θ 和 V_ϕ 跑完一局, 记录 $(s_t, a_t, r_t, V_\phi(s_t))_{t=0}^T$;
2. **计算 GAE 优势:** 从末态向前递推 $\hat{A}_t$; 计算回报目标 $\hat{R}_t = \hat{A}_t + V_\phi(s_t)$;
3. **归一化优势:** $\hat{A}_t \leftarrow (\hat{A}_t - \bar{A})/(\sigma_A + \epsilon)$, 稳定梯度幅值;

4. Critic 更新 (高学习率):

$$L_{\text{critic}} = \frac{1}{2} \left\| V_{\phi}(s_t) - \hat{R}_t \right\|^2, \quad \text{梯度裁剪后以 } \alpha_w \text{ 步进}$$

5. Actor 更新 (低学习率):

$$L_{\text{actor}} = -\hat{A}_t \log \pi_{\theta}(a_t | s_t) - \beta \mathcal{H}[\pi_{\theta}(\cdot | s_t)], \quad \text{梯度裁剪后以 } \alpha_{\theta} \text{ 步进。}$$

实验结果

图 3 展示了 5 个随机种子的 mean $\pm$ 1 std 收益曲线: A2C 从第 ~ 50 轮起稳定上升, 第 500 轮均值达到 ≈ 310 , 且曲线仍在上升 (未完全收敛); 朴素 AC 全程贴近 x 轴, 两者在 episode 50 之后就完全分离。




图 3: A2C 与朴素 Actor-Critic 在 CartPole-v1 上的收敛对比 (5 seeds, mean $\pm$ 1 std, 相同网络结构, 仅训练方式不同)。

回顾图 2 的 A2C 曲线 (红色钟形): 前 ~ 280 轮优势信号持续增大, 对应 Fig 3 中收益快速上升的阶段——策略改进速度 $>$ Critic 追赶速度; 之后随 Critic 追上而平滑回落, 收益曲线斜率也随之减缓。Critic 与 Actor 的「追赶」动态, 正是两时间尺度设计想要保持的健康状态。

算法对比总结

方法	优势估计	更新时机	偏差 / 方差
REINFORCE	G_t	回合结束	低偏差，极高方差
REINFORCE + Baseline	$G_t - V(s_t)$	回合结束	低偏差，高方差（改善）
朴素 AC	δ_t	每步在线	高偏差，低方差（但坍缩）
A2C	$\hat{A}^{\text{GAE}(\gamma, \lambda)}$	回合后批量	λ 可调，稳定

为什么 A2C 不直接用 Monte Carlo 回报？

用纯 MC 回报 G_t 作为 Critic 目标，等同于 REINFORCE with baseline——bootstrap 的方差优势消失，退化为在线 MC 更新。在 CartPole-v1 这样的短回合任务中 MC 尚可用，但在连续控制（关节角度、速度等高维动作空间）+ 长回合任务中， G_t 的方差会大到无法收敛。GAE 的 λ 参数提供了偏差-方差的连续插值，而不必在两个极端中二选一。

为什么 Critic 学习率要高于 Actor？

两时间尺度定理 (Konda & Tsitsiklis 2003)：Actor-Critic 收敛需满足：

$$\sum_k \alpha_\theta(k) = \infty, \quad \sum_k \alpha_w(k) = \infty, \quad \frac{\alpha_\theta(k)}{\alpha_w(k)} \rightarrow 0 \quad (k \rightarrow \infty)$$

直觉：如果 Actor 和 Critic 以相同速度变化，Critic 永远在追移动靶（策略一直在变）；Critic 学得更快，就能在 Actor 下次更新前近似收敛到当前策略的 V^π ，保证 Actor 拿到的是「对当前策略的准确评估」，梯度方向可信。

本章在 RL 体系中的位置

Actor-Critic 是从基础算法迈向现代深度 RL 的关键桥梁：

- TD 路线（基于值）**：MAB $\rightarrow$ MDP / Bellman 方程 $\rightarrow$ TD(0) / Q-Learning $\rightarrow$ DQN。DQN 学的是 $Q(s, a)$ ，是纯 Critic，没有显式 Actor；无法处理连续动作空间。
- MC 路线（基于策略）**：REINFORCE 直接优化 π_θ ，是纯 Actor，没有 Critic；方差极大，样本效率低。
- Actor-Critic 路线（融合）**：本章将两条路线合并——Actor 优化策略，Critic 提供低方差基准。GAE 控制偏差-方差权衡 $\rightarrow$ **PPO**（下一章）在 AC 框架上加 clip 约束，限制每步策略更新幅度，避免步长过大破坏已有策略 $\rightarrow$ **SAC** 在最大熵框架下自动调节温度系数 β ，将熵正则化推向更严格的理论基础。
- 离线 RL 的影子**：IQL (Implicit Q-Learning) 等离线方法中，Critic 仍然需要准确的价值估计；两时间尺度原则以不同形式复现——如何在数据集覆盖不足时让 Critic 不过拟合超出分布的状态，正是离线 RL 要回答的核心问题。

把 PPO 的 clip 目标去掉，只保留 GAE + 熵 + 梯度裁剪，你得到的和本章 A2C 有多大区别——PPO 的 clip 究竟防止了什么？

参考资料

1. Konda & Tsitsiklis (2003). On actor-critic algorithms. *SIAM Journal on Control and Optimization*, 42(4).
2. Sutton & Barto (2018). *Reinforcement Learning: An Introduction* (2nd ed.). Chapter 13.
3. Schulman et al. (2015). High-dimensional continuous control using generalized advantage estimation. *ICLR 2016*.
4. Mnih et al. (2016). Asynchronous methods for deep reinforcement learning (A3C). *ICML*.
5. 动手学强化学习 (Hands-on-RL) . 第 12 章: Actor-Critic 算法.