

直接偏好优化 (DPO / Direct Preference Optimization)

先讲一个故事

第 11 章的 RLHF 管线能用，但它很重：先训一个奖励模型，再跑一整套 PPO——两阶段、两个模型、外加采样训练的全部不稳定性。工程师看着这条管线会问一个自然的问题：偏好数据里的信息，为什么要先「压缩」成奖励模型，再让 RL「解压」回策略？

错误做法 / 朴素做法：直接在胜出样本上做监督微调（只学 y_w 、丢掉 y_l ）。这退化为 SFT，丢失了「比较」中最有价值的信息——差在哪里。

本章方法的做法：注意到 KL 正则的奖励最大化有**闭式最优解**，把奖励用最优策略反解出来、代回偏好似然——奖励模型和 PPO 同时消失，剩下一个纯监督损失。

本章的核心问题：省掉了奖励模型这个组件，是否也省掉了奖励模型的病？

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}_{(y_w, y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w)}{\pi_{\text{ref}}(y_w)} - \beta \log \frac{\pi_{\theta}(y_l)}{\pi_{\text{ref}}(y_l)} \right) \right]$$

数学形式化

从第 11 章的目标出发： $\max_{\pi} \mathbb{E}_{y \sim \pi} [r(y)] - \beta \text{KL}(\pi \| \pi_{\text{ref}})$ 。它的最优解有闭式形式：

$$\pi^*(y) = \frac{1}{Z} \pi_{\text{ref}}(y) \exp \left(\frac{r(y)}{\beta} \right)$$

反解出奖励： $r(y) = \beta \log \frac{\pi^*(y)}{\pi_{\text{ref}}(y)} + \beta \log Z$ 。代入 Bradley-Terry 似然 $P(y_w \succ y_l) = \sigma(r(y_w) - r(y_l))$ 时，配分函数 Z 在差中消去，得到上面的 DPO 损失。

- π_{θ} ——待优化策略，同时扮演「隐式奖励模型」；
- π_{ref} ——冻结的参考策略（SFT 模型）；
- β ——与第 11 章同源的 KL 系数，这里进入损失内部；
- $\hat{r}_{\theta}(y) = \beta \log \frac{\pi_{\theta}(y)}{\pi_{\text{ref}}(y)}$ ——隐式奖励，训练 DPO 就是在拟合它。

为什么可以省掉奖励模型

策略即奖励模型

BT 似然只依赖奖励差，而最优策略与奖励在差的意义上——对应——策略的对数比值就是奖励。于是「先学奖励、再解出策略」的两步，可以合并成「直接学策略」的一步：DPO 是同一个优化问题的解析捷径，不是一个新目标。

实验在与第 11 章完全相同的玩具任务和同一份 4000 偏好对上对比两条路：RLHF 管线（奖励模型 + PPO， $\beta = 0.5$ ）最终真实分数约 +0.84；DPO（ $\beta = 2.0$ ）在约 1200 步处越过这条线，峰值约 +0.94 ~ +1.05——不训奖励模型、不做采样训练，效果相当（图 1）。

Fig 1. DPO matches the RLHF pipeline on the same pairs
(3 seeds, mean $\pm$ std)




图 1: 同一份 4000 偏好对上, DPO ($\beta = 2.0$) 与第 11 章 RLHF 管线 (奖励模型 + PPO, $\beta = 0.5$) 的对比 (3 个随机种子, 阴影为 $\pm 1\sigma$)。DPO 在约 1200 步处越过 RLHF 的最终水平 (虚线, +0.84); 2000 步后均值缓慢回落、种子间方差扩大——漂移开始 (见图 3)。

核心机制

机制一：隐式奖励，同一个病

DPO 训练在拟合隐式奖励 $\hat{r}_\theta = \beta \log(\pi_\theta / \pi_{\text{ref}})$ ，而它和第 11 章的显式奖励模型受同一条规律支配：**只在偏好数据覆盖区内可信**。把训练后策略的隐式奖励按强调 token 数分组测量 (图 2)：覆盖区内与真实分数同向上升；覆盖区外真实分数见顶崩坏，隐式奖励继续单调上扬——与第 11 章图 1 右侧的外推曲线如出一辙。绕开了奖励模型这个组件，绕不开「奖励来自有限覆盖的数据」这个事实。

机制二：软锚—— β 与训练时长共同决定漂移

第 11 章的 KL 惩罚是目标里的显式项；DPO 的 β 藏在损失内部，是一个**软锚**。梯度权重为 $\sigma(-\beta \cdot \text{margin})$ ：margin 越大权重越小，但只要损失未饱和， $\log(\pi_\theta / \pi_{\text{ref}})$ 的差距就会被持续放大。 β 小则饱和慢、放大快。

关键的实验事实 (图 3)：DPO **从不采样自己的生成**，但 token 级的泛化偏移照样把生成分布推出覆盖区—— $\beta = 0.1$ 在数百步内崩塌 (最终约 -3.8)； $\beta = 0.5$ 更慢但同样崩塌 (约 -4.1)； $\beta = 2.0$ 稳定在约 $+0.85$ ，但后期种子间方差扩大，漂移已经开始。训练步数因此是 DPO 的**隐藏超参**：early stopping 不是可选项，而是锚的一部分。

机制三：梯度形态——自带难例加权

把 DPO 损失对 θ 求导：梯度前的标量权重是 $\sigma(-\beta \cdot \text{margin})$ ——当前分错 (margin 为负) 的偏好对权重接近 1，已经分对且 margin 很大的对权重趋近 0。DPO 天然把学习压力集中在「策略




图 2: 训练后策略 ($\beta = 0.1$, 即图 3 中崩溃的一组) 的隐式奖励 $\beta \log(\pi/\pi_{\text{ref}})$ 按强调 token 数 c_E 分组 (3 个随机种子, 阴影为 $\pm 1\sigma$)。偏好数据覆盖区 (灰色, $c_E \leq 3$) 内隐式奖励与真实分数同向; 覆盖区外真实分数崩坏、隐式奖励继续单调上扬——与第 11 章显式奖励模型的外推曲线同构。




图 3: β 扫描 (3 个随机种子, 阴影为 $\pm 1\sigma$, 点虚线为 SFT 基线 $+0.39$)。 $\beta = 0.1$ 先短暂冲高、随后数百步内崩溃 (最终约 -3.8); $\beta = 0.5$ 崩得更慢但同样崩溃 (约 -4.1); $\beta = 2.0$ 稳定在约 $+0.85$, 后期方差扩大——DPO 的锚随训练时长松动。

还没分清」的比较上，这是它训练稳定的一个来源。

完整算法流程

DPO 三步

1. **SFT**: 得到参考策略 π_{ref} , 冻结;
2. **偏好收集**: 从 π_{ref} 采样成对候选并标注 (与 RLHF 相同);
3. **直接优化**: 初始化 $\pi_{\theta} \leftarrow \pi_{\text{ref}}$, 最小化 $\mathcal{L}_{\text{DPO}}$; 序列对数概率按 token 求和, margin 用「策略减参考」的差再作差; 用生成质量或验证集 KL 决定停止时机。

与相邻方法对比

DPO vs RLHF

- **组件**: RLHF 需要奖励模型 + PPO (采样、优势估计、比值裁剪); DPO 只有一个监督损失;
- **失败模式**: 同一个病 (覆盖区外的乐观外推), 不同的发作方式——PPO 靠采样**主动搜索**分叉方向, DPO 靠泛化**被动漂移**出去; 前者崩得急 (第 11 章 60 轮内), 后者由 β 与训练时长共同决定快慢;
- **锚的性质**: RLHF 的 KL 是目标中的显式惩罚, DPO 的 β 是损失内的软锚——软锚会随训练松动, 必须配合 early stopping。

本章在 RL 体系中的位置

1. 上游: RLHF (第 11 章) 给出目标——KL 正则的偏好奖励最大化;
2. 直接偏好优化 (DPO) (本章: 同一目标的解析捷径, 策略即奖励模型);
3. 下游: GRPO 与可验证奖励 (RLVR) ——当任务的对错可以由规则判定时, 用可验证奖励替代学习奖励, 「奖励被击穿」从根上不再可能。

读者应带走一句话: **DPO 改变的是实现路径, 不是问题的结构——偏好数据的覆盖区仍然是可优化的边界, 只是这一次, 越界靠的不是采样器的搜索, 而是网络自己的泛化。**下一章我们换掉奖励的来源。

参考资料

1. Rafailov et al. (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. *NeurIPS*.
2. Azar et al. (2024). A General Theoretical Paradigm to Understand Learning from Human Preferences (IPO). *AISTATS*.
3. Tunstall et al. (2023). Zephyr: Direct Distillation of LM Alignment. *arXiv:2310.16944*.

4. Ouyang et al. (2022). Training Language Models to Follow Instructions with Human Feedback.
NeurIPS.