

GRPO 与可验证奖励 (RLVR / Reinforcement Learning with Verifiable Rewards)

先讲一个故事

前两章的所有麻烦都出自同一个源头：奖励是从有限覆盖的偏好数据里学出来的代理，代理与真实之间的缝隙会被优化器无限放大。但很多任务根本不需要学奖励——数学题的答案对不对，一条规则就能判；代码对不对，跑一遍测试就知道。

错误做法 / 朴素做法：给会判分的任务也训一个奖励模型。它会从数据里学到「看起来对」的特征，然后被优化器击穿——第 11 章的全部剧情重演一遍。

本章方法的做法：能验证就别学。用规则验证器直接给出奖励（对 = 1、错 = 0），配一个不需要 Critic 的策略梯度算法——GRPO：同一提示采样一组回答，用组内相对表现作为优势。

本章的核心问题：当奖励不可击穿之后，新的瓶颈是什么？

$$\hat{A}_i = \frac{r_i - \text{mean}(r_1, \dots, r_G)}{\text{std}(r_1, \dots, r_G)}$$

数学形式化

对每个提示 x ，从当前策略采样 G 个补全 $\{y_i\}_{i=1}^G$ ，验证器给出奖励 $r_i = \text{verify}(x, y_i) \in \{0, 1\}$ 。GRPO 的目标与 PPO 同构，但优势由组内标准化给出：

$$J(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \min \left(\rho_i \hat{A}_i, \text{clip}(\rho_i, 1-\epsilon, 1+\epsilon) \hat{A}_i \right) \right]$$

- **verify** ——规则验证器：精确匹配、单元测试、约束检查，不含可学习参数；
- G ——组大小，同一提示的采样数，组内均值扮演该提示专属的基线；
- ρ_i ——新旧策略在补全 y_i 上的概率比值，与第 7 章的 PPO-clip 相同；
- $\hat{A}_i$ ——组相对优势：不需要价值网络，按提示难度自动归一。

任务设计：让基础模型「自信地错」

实验用两位数加法：提示为「 $d\ d + d\ d =$ 」，补全 3 位数字，奖励为精确匹配。关键设计在 SFT 教师：它以 0.3 的概率给出正确答案，以 0.7 的概率给出**逐位相加不进位**的答案。于是在带进位的题目上，错误答案是数据的众数——基础模型贪心解码时进位准确率为 0，这不是噪声，是学进去的**系统性错误算法**。

这正是学习奖励无能为力的情形：奖励模型也从同一份有偏数据里学，只会把「不进位」学成高分特征。而规则验证器不看数据看答案：对就是对。GRPO 借助采样中残存的约三成正率作为信号，约 20 轮把整体准确率从 0.30 拉到 1.00，进位准确率从 0 拉到 1.00（图 1）。

Fig 1. Verifiable reward overturns a systematic error
(3 seeds, mean $\pm$ std)




图 1: 可验证奖励推翻系统性错误 (两位数加法, 3 个随机种子, 阴影为 $\pm 1\sigma$, 点虚线为 SFT 基线)。教师「不会进位」, SFT 基础模型整体准确率 0.32、进位题准确率 0.03; GRPO 约 20 轮把两者都拉到 1.00。

核心机制

机制一：不可击穿的奖励

第 11 章里 $\beta = 0$ 的 PPO 在 60 轮内击穿学习奖励；第 12 章里 DPO 的软锚随训练松动。这里同样 $\beta = 0$ 、长训 600 轮：准确率到顶后纹丝不动，对参考策略的 KL 稳定在约 1 nat（图 2）。

原因不在算法在奖励：**验证器与真实目标是同一个函数**，代理与真实之间没有可分叉的缝隙，优化再狠也只能把正确答案学得更牢。KL 锚定从必需品变成可选项。剩下的风险只有一个——验证器本身有没有漏洞（答案格式绕过、测试用例不全），那是工程问题，不再是学习问题。

机制二：组相对基线——用对比替代 Critic

PPO 需要价值网络估计基线，GRPO 用「同一提示、一组回答」的组内均值替代：容易的提示组内全对、困难的提示组内全错，优势自动按提示难度归一，不需要任何额外网络。组内均值与第 7 章的全局批基线同为基线的一种（本章聚焦组机制，未做两者对照）——组机制的独特行为在下一个机制里显形。

机制三：零信号组——新的瓶颈是信号

可验证奖励通常是稀疏的 0/1。组相对优势依赖**组内差异**：全对或全错的组标准差为零，优势恒为零，梯度恒为零。把教师换成从不给对进位题 ($q = 0$)：冷启动模型在进位题上采样成功率 ≈ 0 ，每个组要么全对（无进位题）要么全错（进位题），零信号组占比恒为 100%——学习从未开始，准确率永远停在 0.30（图 3）。

Fig 2. $\beta = 0$, 600 iterations: nothing collapses
(3 seeds, mean $\pm$ std)




图 2: $\beta = 0$ 、600 轮长训（3 个随机种子，阴影为 $\pm 1\sigma$ ）。准确率（左轴）到顶后保持 1.00，KL（右轴）稳定在约 1 nat——对照第 11 章 $\beta = 0$ 的崩塌与第 12 章的软锚松动：可验证奖励下无锚也不崩。

同一个统计量在弱教师起点下讲另一个故事：零信号组占比从约三成升到接近 100%，因为题目全部练会了——「毕业」。全组分分有两种含义，只有看着准确率才能分辨。这就是推理模型训练需要冷启动 SFT 数据与课程设计的原因：可验证奖励解决了「奖励可靠性」，把难题留给了「探索与信号密度」。

Fig 3. Cold start: all-same groups carry no gradient (3 seeds, mean $\pm$ std)




图 3: 冷启动之死（3 个随机种子，阴影为 $\pm 1\sigma$ ）。左：弱教师起点（蓝）升到 1.00，冷启动（红，教师从不给对进位题）停在 0.30。右：零信号组占比——冷启动恒为 100%（全组分分、零梯度），弱教师起点从约三成升到接近 100%（题目练会、毕业）。

完整算法流程

GRPO 一轮迭代

1. **采样**: 取一批提示, 每个提示从当前策略采样 G 个补全;
2. **验证**: 规则验证器逐个打分 $r_i \in \{0, 1\}$;
3. **组内标准化**: 按提示分组计算 $\hat{A}_i = (r_i - \bar{r})/\text{std}(r)$, 全组同分的组优势为零;
4. **更新**: PPO-clip 目标、多轮小批量更新; 可选地叠加 $-\beta \text{KL}$ (本章实验 $\beta = 0$)。

与相邻方法对比

GRPO vs PPO, RLVR vs RLHF

- **GRPO vs PPO**: 去掉价值网络, 用组内对比替代基线估计——少训一个模型, 代价是每个提示要采样 G 次、且依赖组内差异存在;
- **RLVR vs RLHF**: 奖励来源从「人类偏好建模」换成「规则验证」——击穿奖励从根上不可能, 但适用范围收窄到可判定的任务; 瓶颈从奖励可靠性转移到奖励稀疏性与起点质量。

本章在 RL 体系中的位置

1. 上游: RLHF (第 11 章) 与 DPO (第 12 章) ——奖励从数据中学习, 覆盖区决定可优化边界;
2. GRPO 与可验证奖励 (本章: 能验证就别学, 瓶颈从奖励转移到信号);
3. 下游: 过程奖励、课程与自动验证器构造——把更多任务变成「可验证」的形状。

三章弧线就此收束。奖励的可靠性排序从此清晰: **规则验证** > **人类偏好建模** > **手工设计**。RLHF 教会我们奖励可以学但会被击穿; DPO 教会我们绕开组件绕不开覆盖区; RLVR 教会我们——能验证就别学, 然后把力气花在起点、课程和探索上。

参考资料

1. Shao et al. (2024). DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models (GRPO). *arXiv:2402.03300*.
2. DeepSeek-AI (2025). DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. *arXiv:2501.12948*.
3. Lambert et al. (2024). Tulu 3: Pushing Frontiers in Open Language Model Post-Training (RLVR). *arXiv:2411.15124*.
4. Schulman et al. (2017). Proximal Policy Optimization Algorithms. *arXiv:1707.06347*.