

马尔可夫决策过程 (Markov Decision Process, MDP)

先讲一个故事

想象你是一只小老鼠，住在一个 3×3 的迷宫里。你每次可以上、下、左、右走一步。走到奶酪格子得 +1 分，走到电击格子得 -1 分，其他格子不得分。你的目标是：找到一条路，让长期累积的分数最多。

这个故事就是一个 MDP。下面把故事里的要素翻译成数学语言。

数学形式化：五元组

MDP 由五个要素完整描述：

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma)$$

- $\mathcal{S}$ —— **状态空间**。所有可能状态的集合（迷宫例中 $\mathcal{S} = \{1, \dots, 9\}$ 九个格子）；
- $\mathcal{A}$ —— **动作空间**。所有可能动作的集合（ $\mathcal{A} = \{\uparrow, \downarrow, \leftarrow, \rightarrow\}$, $|\mathcal{A}| = 4$ ）；
- $\mathcal{P}$ —— **状态转移概率**。MDP 的 Markov 性质核心——下一状态只依赖当前状态与动作，与更早的历史无关：

$$P(S_{t+1} = s' \mid S_t = s, A_t = a, S_{t-1}, A_{t-1}, \dots, S_0) = P(S_{t+1} = s' \mid S_t = s, A_t = a)$$

简记 $P_{ss'}^a = P(s' \mid s, a)$ 。对任意 s, a ，它构成一个分布： $\sum_{s' \in \mathcal{S}} P(s' \mid s, a) = 1$ ；

- $\mathcal{R}$ —— **奖励函数**。 $R(s, a) = \mathbb{E}[R_{t+1} \mid S_t = s, A_t = a]$ 是在状态 s 采取动作 a 后获得的即时奖励的期望（也可写成 $R(s, a, s')$ 形式）；
- $\gamma \in [0, 1)$ —— **折扣因子**。 $\gamma \rightarrow 0$ 只看眼前， $\gamma \rightarrow 1$ 注重长期累积； $\gamma < 1$ 数学上保证无限时域回报级数收敛（若奖励有界）。

交互过程

Agent 与环境在离散时间步 $t = 0, 1, 2, \dots$ 上交互，每一步产生一个四元组 $(S_t, A_t, R_{t+1}, S_{t+1})$ ，完整轨迹为：

$$S_0, A_0, R_1, S_1, A_1, R_2, S_2, \dots$$

这个序列的联合分布由转移概率 $\mathcal{P}$ 和策略 π 共同决定——这就是强化学习全部数据的来源：试错、拿反馈、调整、再来。

价值函数——什么是「好」状态

回报 (Return)

不能光看脚下一步的奖励——奶酪可能在隔壁，也可能在十步之外。定义**折扣回报**：

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

把未来的所有奖励加起来，离现在越远折扣越重。其递归形式是后续所有 Bellman 推导的起点：

$$G_t = R_{t+1} + \gamma G_{t+1}$$

价值函数：回报的条件期望

因为转移是随机的，你无法精确预测未来，只能求期望：

$$v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s], \quad q_\pi(s, a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$$

- $v_\pi(s)$ —— 给定策略 π ，从状态 s 出发平均能拿多少回报（**状态价值**）；
- $q_\pi(s, a)$ —— 在状态 s 先执行动作 a ，之后按 π 行动，平均能拿多少回报（**动作价值**）。

一句话：价值不是精确的未来，而是对未来回报的条件期望。

v_π 与 q_π 的关系

由定义立即可得二者互推：

$$v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) q_\pi(s, a)$$
$$q_\pi(s, a) = R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' \mid s, a) v_\pi(s')$$

状态价值 = 按策略对动作价值加权平均；动作价值 = 即时奖励 + 折扣后后继状态价值的期望。这两个关系在后面推导 Bellman 方程时反复用到。

Bellman 期望方程——把未来拆成「眼前 + 之后」

推导

Bellman 的关键发现是：价值可以递归地定义。从 $G_t = R_{t+1} + \gamma G_{t+1}$ 出发：

$$\begin{aligned} v_\pi(s) &= \mathbb{E}_\pi[G_t \mid S_t = s] \\ &= \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \\ &= \mathbb{E}_\pi[R_{t+1} \mid S_t = s] + \gamma \mathbb{E}_\pi[G_{t+1} \mid S_t = s] \end{aligned}$$

第一项是即时奖励的期望，第二项是后继价值的期望。对动作 a 与后继状态 s' 展开求和：

$$v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) \left[R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' \mid s, a) v_\pi(s') \right]$$

它说：你不需要看无限远的未来，只需看一步，然后用下一个状态的价值估计余下的。动作价值的 Bellman 期望方程同理：

$$q_\pi(s, a) = R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' \mid s, a) \sum_{a' \in \mathcal{A}} \pi(a' \mid s') q_\pi(s', a')$$

一个具体例子

假设你在格子 A，往右走必到格子 B，奖励 $R = 0$ 。若 $v(B) = 5$ ， $\gamma = 0.9$ ：

$$q(A, \rightarrow) = 0 + 0.9 \times 5 = 4.5$$

格子 A 本身没奖励，但因为右边是「好地方」，A 也是好地方。这就是 Bellman 方程的直观威力——价值通过递归在状态间传播。

矩阵形式（有限状态 MDP）

状态空间有限时，Bellman 期望方程是线性方程组：

$$v_\pi = R_\pi + \gamma P_\pi v_\pi$$

其中 $v_\pi \in \mathbb{R}^{|S|}$ ， $R_\pi(s) = \sum_a \pi(a | s) R(s, a)$ ， $P_\pi(s, s') = \sum_a \pi(a | s) P(s' | s, a)$ 。可直接求闭式解：

$$v_\pi = (I - \gamma P_\pi)^{-1} R_\pi$$

这是唯一能写闭式解的地方——最优方程就没有这么幸运了。

Bellman 最优方程——每一步都选最好的

最优价值函数

定义最优价值函数为所有策略中的最大值：

$$v_*(s) = \max_{\pi} v_\pi(s), \quad \forall s \in S, \quad q_*(s, a) = \max_{\pi} q_\pi(s, a), \quad \forall s \in S, a \in \mathcal{A}$$

对有限 MDP，最优策略 π_* 一定存在且满足 $v_{\pi_*} = v_*$ （逐状态）；并有 $v_*(s) = \max_a q_*(s, a)$ 。

状态价值的最优方程推导

把 Bellman 期望方程中的「按策略加权平均」换成「取最大」：

$$v_*(s) = \max_{a \in \mathcal{A}} \left[R(s, a) + \gamma \sum_{s' \in S} P(s' | s, a) v_*(s') \right]$$

更严格地从定义出发：设 π_* 为最优策略，则 $v_{\pi_*} = v_*$ 、 $q_{\pi_*} = q_*$ 。把 $v_* = v_{\pi_*}$ 代入动作价值的 Bellman 期望方程 $q_*(s, a) = R(s, a) + \gamma \sum_{s'} P(s' | s, a) v_*(s')$ ，再利用 $v_* = \max_a q_*$ 对 a 取最大：

$$v_*(s) = \max_a q_*(s, a) = \max_a \left[R(s, a) + \gamma \sum_{s' \in S} P(s' | s, a) v_*(s') \right]$$

和期望方程的区别只有一个： $\sum_a \pi(a | s)$ 换成了 $\max_a$ 。动作价值的最优方程：

$$q_*(s, a) = R(s, a) + \gamma \sum_{s' \in S} P(s' | s, a) \max_{a' \in \mathcal{A}} q_*(s', a')$$

为什么没有闭式解？

Bellman 期望方程是线性的（可求逆），最优方程却是**非线性**的—— $\max$ 算子破坏了线性结构，无法求逆，只能迭代逼近：

$$v_\pi = R_\pi + \gamma P_\pi v_\pi \implies v_\pi = (I - \gamma P_\pi)^{-1} R_\pi \quad (\text{线性, 可求逆})$$

$$v_* = \max_a (R_a + \gamma P_a v_*) \quad (\text{非线性, 含 } \max, \text{ 无法求逆})$$

这就是下一节动态规划（值迭代、策略迭代）出现的原因。

从方程到算法：策略提升与动态规划

策略提升定理

给定任意策略 π 与它的 q_π ，构造新策略 $\pi'(s) = \arg \max_a q_\pi(s, a)$ ，则 π' **不差于** π （即 $v_{\pi'} \geq v_\pi$ 逐分量成立），这称为**策略提升定理**。反复交替「评估 $\rightarrow$ 提升」至不动点，即收敛到最优策略 π_* 。

动态规划三件套

已知模型 $\mathcal{P}$ 、 $\mathcal{R}$ 时，可以精确求解 MDP。三套算法在 4×4 GridWorld（右下角为目标格，进入得 +1， $\gamma = 0.9$ ）上的行为如下。

策略评估：迭代 Bellman 期望方程 $V_{k+1}(s) \leftarrow \sum_a \pi(a | s) [R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s')]$ ，收敛到 v_π 。图 1 左图展示几个状态的 $V_k(s)$ 随扫描收敛，右图为收敛后的 v_π 热力图。




图 1: 策略评估 (4×4 GridWorld, 均匀随机策略, $\gamma = 0.9$)。左: 四个状态的 $V_k(s)$ 随扫描次数收敛（紧邻目标的格收敛快、远角格收敛慢）；右: 收敛后 v_π 的热力图。

值迭代：迭代 Bellman 最优方程 $V_{k+1}(s) \leftarrow \max_a [R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s')]$ 。图 2 显示高价值区域像水波一样从目标格逐轮向外扩展。




图 2: 值迭代的价值传播 (4×4 GridWorld, $\gamma = 0.9$)。第 1/2/3 轮与收敛时 (第 7 轮) 的 V_k : 一步可达目标格的格价值最先变为 1.0, 之后每多一轮价值向外辐射一格。

策略迭代: 交替「完整策略评估 $\rightarrow$ 贪心改进」。图 3 对比两种算法的收敛动态。




图 3: 值迭代 vs 策略迭代 (4×4 GridWorld, $\gamma = 0.9$)。左: 值迭代的 Bellman 残差 $\max_s |V_{k+1} - V_k|$ 单调几何衰减 (本例 7 轮收敛); 右: 策略迭代的残差逐扫描呈阶梯下降 (虚线为每次策略改进, 本例 3 轮迭代、约 127 轮扫描)。两种算法收敛到同一个 V^* (数值上 $\max_s |V_*^{VI} - V_*^{PI}| = 0$)。

共性: 三者都需要**已知模型**——DP 用 $P(s' | s, a)$ 对所有后继求期望。现实中模型往往未知, 这正是下一章 TD 学习要打破的假设。

本章在 RL 体系中的位置

1. **上游:** MAB 教会我们探索 vs. 利用与增量更新 $\theta \leftarrow \theta + \alpha(\text{Target} - \theta)$;
2. **本章 (MDP):** 把单状态扩展为带转移的序列决策, 用 $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma)$ 五元组、价值函数与 Bellman 方程搭起整个 RL 的理论骨架;
3. **下游:** Bellman 方程是后面一切的递归根基——TD 学习把「对所有后继求期望」换成「采样一次」; DQN 用神经网络逼近 Q ; 策略梯度直接在策略空间优化。

学完本章, 你应该能看懂任何 MDP 的「问题定义」, 并且理解价值函数为什么可以递归定义、最优方程为什么没有闭式解。下一章进入 TD 学习: 去掉「已知模型」这个最强假设。

参考资料

1. Sutton & Barto (2018). *Reinforcement Learning: An Introduction* (2nd ed.). Chapters 3–4.

2. Bellman, R. (1957). *Dynamic Programming*. Princeton University Press.
3. Puterman, M. L. (1994). *Markov Decision Processes*. Wiley.
4. 动手学强化学习 (Hands-on-RL) . 第 3 章: 马尔可夫决策过程.