

离线强化学习：CQL 与 IQL (Offline RL)

先讲一个故事

一支球队的教练拿到了一份特殊的任务：球队已经解散，他没办法再带队上训练场，手里只有一本过去赛季的比赛录像集。录像里记录了每一场比赛的完整过程——谁在什么局势下做了什么决定，结果如何。他要仅凭这本录像，写出一套下一场比赛的战术手册。

朴素 RL 的做法：把录像当作免费的训练场，反复回放、反复演练，让 Q 函数和策略在网络里「练」到收敛。

结果出人意料：反复演练的战术手册在录像覆盖过的场景里还行，可一旦涉及录像里从没出现过的场景，教练编出来的指令荒谬到离谱——整体水平甚至不如照着录像原样抄一遍（行为克隆）。

本章的核心问题：只有一份固定、不能再与真实环境交互的数据集时，如何学到不塌缩的策略？

$$\text{只能访问固定数据集 } \mathcal{D} = \{(s, a, r, s', d)\}, \text{ 目标是学到 } \pi \text{ 使 } \mathbb{E}_{\pi} \left[\sum_t \gamma^t r_t \right] \text{ 最大}$$

这一场病叫**分布漂移 (distribution shift)**：离线学到的策略会去「询问」数据集几乎没有覆盖的状态—动作对，而网络对这些地方的回答完全失真，误差被自举逐步放大。

好消息是，这个领域有两套同样重要、同样成熟的「药方」，它们选择了截然不同的治病思路：

CQL (方案一)：即使必须预测没见过的动作，也**把它们的价值估计压低**——把悲观写进价值函数。

IQL (方案二)：**根本不去预测没见过的动作**——只在数据支持的范围内挑高价值动作，把悲观写进动作集合。

数学形式化

离线数据集： $\mathcal{D}$ 由某个**行为策略 (behavior policy)** μ 采样产生，覆盖范围由 μ 的占用分布 $d^{\mu}(s, a)$ 决定。数据是一次性的， $\mathcal{D}$ 不可再扩大。

- $\mathcal{D}$ —— 固定数据集，训练期间只读不改；
- μ —— 行为策略， $\mathcal{D}$ 的「出身」，我们拿不到也不能再用它交互；
- $d^{\mu}(s, a)$ —— 行为策略的占用分布，数据只覆盖它的支撑集；
- $a \sim \pi(\cdot|s)$ vs $a \sim \mu(\cdot|s)$ —— 学到的策略与数据分布不匹配，这就是分布漂移的来源。

翻译成成人话：在线 RL 里，策略每走一步都可以回到真实环境求证，错了立即纠正；离线 RL 里没有求证的机会，网络一旦问出数据之外的问题，得到的答案没有人不在乎是不是真的。

外推误差：朴素离线 Q-learning 为什么塌缩

max 是罪魁祸首

回忆 DQN 的目标值：

$$y = r + \gamma \max_{a'} Q_{\bar{\theta}}(s', a')$$

在线时，持续交互会不断用新数据校准 max 挑中的高估动作；离线时，max 遍历的是网络对**所有动作**（包括数据集里从未出现过的动作）的估计，且再没有新数据来修正它们。对于没见过的动

作， $Q_{\bar{\theta}}(s', a')$ 从没有被任何目标值校准过，它的取值是网络「自由发挥」的——max 会稳定地选中「相对最高」的那个，而它往往正是数据外、不可信的那个。这个不可信的高值再作为自举目标反向放大，Q 估计与真实价值逐渐**脱钩**，贪心策略据此行动，真实回报随之崩盘（图 1）。

Fujimoto 等把其中最主要的来源——动作不存在于数据——称为**外推误差 (extrapolation error)**；Levine 等（2020）的综述进一步把这类误差归纳为三类来源：

- **动作不存在于数据**：max 选中的 a' 在 $\mathcal{D}$ 中从未出现，Q 对它没有依据；
- **状态不匹配**： s' 在 $\mathcal{D}$ 中罕见（或从未出现），该状态下的所有动作估计都不可信；
- **环境动态不匹配**：即使 (s', a') 在数据里，离线假定的转移与真实环境也可能不同。




图 1: 朴素离线 DQN 的外推误差塌缩 (CartPole-v1, medium 数据集, 3 个随机种子, 阴影为 $\pm 1\sigma$)。同一张图里：蓝色曲线（左轴）是 Q 网络对数据状态的最大 Q 估计——它不再跟踪策略的真实价值；红色曲线（右轴）是贪心策略的真实回报，短暂改善后回落，且始终远低于行为克隆（BC）这条「及格线」（BC 约 300，见图 2 的灰色区间）。Q 估计与真实回报脱钩——正是外推误差进入自举目标后的表现。

Q 值与真实价值的脱钩

过估计不直接等同于「Q 数值大」。诊断离线算法不能只看 Q 的高低，而要看 **Q 估计与真实回报是否脱钩**：图 1 中朴素离线 DQN 的回报先升后跌、始终远低于 BC，而 Q 估计并不反映策略的真实价值——Q 的高低，并不代表策略好坏。一个健康的算法应该让 Q 与回报**同步**：价值兑现为回报，回报反过来印证价值。CQL 与 IQL 正是通过掐断数据外高值的来源，把回报稳定恢复到 BC 水平（图 2、图 3）。

及格线：行为克隆 (Behavior Cloning)

在给出两套药方之前，先立一条参照线。

行为克隆把离线学习变成一个纯监督学习问题：直接拟合行为策略，

$$\pi_{BC} = \arg \max_{\pi} \mathbb{E}_{(s,a) \sim \mathcal{D}} [\log \pi(a|s)]$$

BC 的上限是**数据集本身的质量**：再好的监督拟合也复现不出数据里没有出现过的行为。注意，「数据集的质量」不等于行为策略 μ 的平均水平——本章数据由 μ 以 $\varepsilon = 0.3$ 的随机性采集（ μ 平均回报约 111），数据里仍有约 70% 的状态—动作对来自贪心决策，BC 可以从中「去噪」，恢复出比 μ 平均水平更好的策略（约 300，均值）。因此 BC 的意义不在「复刻 μ 」，而在**给离线学习立一条不塌缩的及格线**。

BC 的下限意义是：它告诉我们**不塌缩**的最低要求。朴素离线 Q-learning 连 BC 都打不过（图 1），说明它的失败不是「学得不够好」，而是「学坏了」——方向错了。一个合格的离线算法至少要把回报恢复到 BC 的水平：

- 数据质量高（expert）时，好的离线算法可以明显**超越** BC；
- 数据质量低（random）时，任何离线算法都**不应低于** BC。

由于 BC 本身有训练方差（本章图中用灰色区间带表示 $\text{mean} \pm 1\sigma$ ），「恢复到 BC 水平」比「严格超过某一个数」更稳健——这也是图 2、图 3 采用的判据。

以下两节就是达到这条及格线的两套方案。

方案一：CQL——把悲观写进价值函数

直觉

保守 Q 学习 (Conservative Q-Learning) 保留对**所有动作**的评估，但给「数据之外的动作」加一笔**悲观惩罚**，压低它们的 Q 估计。惩罚让贪心决策自然落在数据支撑内的动作上——不是不许问，而是问了也知道不值。

保守正则化项

对每个状态 s ，CQL 在标准 Bellman 误差之外加一项正则。其中行为策略 μ 在离线场景下不可知，以数据集中的**经验分布** $\hat{\mu}(a|s)$ 估计之（即状态 s 下各动作在 $\mathcal{D}$ 中的出现频率）：

$$\mathcal{R}(s) = \log \sum_a \exp Q_{\theta}(s, a) - \mathbb{E}_{a \sim \hat{\mu}(\cdot|s)} [Q_{\theta}(s, a)]$$

- $\log \sum_a \exp Q_{\theta}(s, a)$ (logsumexp 项) ——在最小化 L_{CQL} 时把 Q 往下压，且 softmax 权重集中在**高 Q 的动作**上，数据外的高值动作首当其冲；
- $-\mathbb{E}_{a \sim \hat{\mu}(\cdot|s)} [Q_{\theta}(s, a)]$ ——在最小化时把**数据内**动作的 Q 往上抬。

一压一抬：数据内动作的相对价值被抬高，数据外动作的相对价值被压低。整体对 max 的行为没有任何显式约束，但贪心选择的方向被惩罚项拧回了数据内。

完整目标

$$L_{\text{CQL}}(\theta) = \alpha \mathbb{E}_{s \sim \mathcal{D}}[\mathcal{R}(s)] + \frac{1}{2} \mathbb{E}_{(s,a,s') \sim \mathcal{D}} \left[(Q_{\theta}(s,a) - \hat{\mathcal{T}}^{\pi} \bar{Q}(s,a))^2 \right]$$

- 第二项是标准 Bellman 误差， $\hat{\mathcal{T}}^{\pi}$ 为基于样本的贝尔曼算子， Q_{θ} 为目标网络；
- $\alpha > 0$ 是**保守强度**： α 越大，对数据外动作压得越狠（也更保守）； $\alpha \rightarrow 0$ 退化为朴素离线 Q-learning。

为什么这样设计：Q 与回报脱钩的正反馈来源于 max 选中的数据外动作。CQL 不堵 max 的嘴，而是让每个数据外动作的 Q 都「长得比数据内动作慢」，不可信高值的来源被掐断，脱钩随之消失。




图 2: CQL 的保守惩罚恢复回报 (CartPole-v1, medium 数据集, 3 个随机种子, 阴影为 $\pm 1\sigma$, 灰色区间为 BC 的 mean $\pm 1\sigma$)。与朴素离线 DQN 的塌缩 (红色) 形成对比, CQL 的回报 (蓝色) 随离线更新稳步上升到 BC 区间——不再塌缩。同一个框架, 只多一项 $\alpha \mathcal{R}(s)$ 正则, 从「塌缩」到「恢复」——惩罚把 Q 锚定在数据支持的动作上。

方案二: IQL——把悲观写进动作集合

直觉

隐式 Q 学习 (Implicit Q-Learning) 走完全相反的路线: **永远不去评估数据外的动作**。它用一个特殊的回归目标拟合价值函数, 使 V 直接「跳过」max——因为 max 恰恰是数据外误差的来源。

expectile 回归

普通最小二乘拟合的是条件**均值**；IQL 改用 expectile 回归，用超参 $\tau \in (0, 1)$ 控制拟合到条件分布的哪个分位：

$$L_2^\tau(u) = |\tau - \mathbf{1}\{u < 0\}| u^2$$

- $\tau = 0.5$ 退化为普通最小二乘（拟合均值）；
- $\tau > 0.5$ （典型取 $0.7 \sim 0.9$ ）偏向拟合**上分位**——只把「数据内比较好的结果」纳入 V 。

翻译成成人话：在线 Q-learning 用 $\max_{a'} Q(s', \cdot)$ 回答「下一步最好能有多好」；IQL 用 expectile 回答同一句话，但**只依据数据里真实出现过的** (s', a') 。答案既保留了对好动作的乐观，又永远不会跑到数据之外取值。

价值函数与策略更新

V 与 Q 交替回归：

$$V_\psi(s) \leftarrow \arg \min_V \mathbb{E}_{(s,a) \sim \mathcal{D}} [L_2^\tau(Q_{\bar{\theta}}(s, a) - V_\psi(s))]$$

$$Q_\theta(s, a) \leftarrow \arg \min_Q \mathbb{E}_{(s,a,s') \sim \mathcal{D}} [(Q_\theta(s, a) - r - \gamma V_\psi(s'))^2]$$

- V 只从数据内动作的 $Q_{\bar{\theta}}$ 回归， τ 决定它偏向好动作还是均值；
- Q 的目标里**没有** $\max$ ，只有 $r + \gamma V(s')$ ——外推误差没有入口。

策略用 AWR 式的加权监督学习更新：只提升「数据内价值高于 V 」的动作，

$$\pi_\phi \leftarrow \arg \max_\pi \mathbb{E}_{(s,a) \sim \mathcal{D}} \left[\exp\left(\frac{1}{\lambda} (Q_\theta(s, a) - V_\psi(s))\right) \log \pi_\phi(a|s) \right]$$

其中 $\lambda > 0$ 是行为克隆与价值提升之间的**权衡温度**： $\lambda \rightarrow \infty$ 时权重趋于 1，退化为纯 BC； $\lambda \rightarrow 0$ 时权重集中于优势最大的动作，退化为贪心 Q 最大化。

两种悲观的分工：CQL vs IQL

一个病，两种药

	CQL	IQL
悲观的对象	价值函数（压 OOD 的 Q ）	动作集合（不评估 OOD）
是否查询数据外动作	是，但压低其价值	从不
自举目标	带惩罚的 $\max$	$r + \gamma V$ （无 $\max$ ）
关键超参	保守强度 α	期望分位 τ 、温度 λ
核心算子	$\log \sum_a \exp Q$	expectile 回归 L_2^τ

Fig 3. IQL: in-sample learning recovers return to BC level




图 3: IQL 的 in-sample 学习恢复回报 (CartPole-v1, medium 数据集, 3 个随机种子, 阴影为 $\pm 1\sigma$, 灰色区间为 BC 的 $\text{mean} \pm 1\sigma$)。与朴素离线 DQN 的塌缩 (红色) 形成对比, IQL 的回报 (绿色) 随离线更新稳步上升到 BC 区间——不再塌缩。它从不查询数据外动作, 外推误差根本不会进入自举目标。同一个病, 换一种「不问」的药, 同样治好了。

设计哲学的差别: CQL 回答的是「数据外动作值多少」——它强行给出答案, 但给的是负面的 (保守的); IQL 回答的是「不回答数据外动作」——它修改问题本身, 让 max 从算法里消失。前者是给说谎者设罚则, 后者是干脆不问不知道的人。

在实际中: IQL 的 AWR 式策略提取往往更贴合「离线训练 + 在线微调」的流程; CQL 若要在在线微调, 需显式退火保守强度 α ——惩罚项不会随训练自己消失, 过强的保守性会阻碍继续提升。IQL 实现也更简单、对离散/连续动作同样自然——它不需要估计行为策略的动作密度 (连续情形下 CQL 要额外采样 $a \sim \hat{\mu}$), 只需直接用数据里的 (s, a) 对。两者在 D4RL 基准上各有擅长, 但都能把回报稳定恢复到 BC 及格线水平——这正是本章图 2、图 3 想传达的: 两条路殊途同归。

本章在 RL 体系中的位置

1. **值函数路线** $\rightarrow$ DQN (在线 max) $\rightarrow$ 双 Q / 目标网络 (缓解过估计);
2. **Off-policy 路线** $\rightarrow$ SAC (上一章: replay buffer 反复利用) —— 离线 RL 就是「拔掉环境插头, 把 buffer 固化成整个数据集」;
3. **离线强化学习** (本章: 不能交互, 只读固定数据集 $\rightarrow$ 分布漂移 $\rightarrow$ CQL 压 OOD 价值 / IQL 不问 OOD);
4. **下游** $\rightarrow$ 保守思想的延伸 (model-based 离线方法、决策 Transformer 等序列化离线建模)。

离线 RL 是 RL 走向工业落地的关键一环: 真实系统的数据贵、风险高, 很多时候只有历史数据可用。本章的两套方案代表了领域内两种主流的「悲观」设计——约束价值, 或约束动作——它

们共同确立了离线学习的及格线思维：不塌缩（恢复到 BC 水平）比聪明（追最优）更重要。

参考资料

1. Kumar et al. (2020). Conservative Q-Learning for Offline Reinforcement Learning. *NeurIPS*.
2. Kostrikov, Nair & Levine (2021). Offline Reinforcement Learning with Implicit Q-Learning. *NeurIPS*.
3. Fujimoto, Meger & Precup (2019). Off-Policy Deep Reinforcement Learning without Exploration. *ICML*.
4. Levine et al. (2020). Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Practical Applications. *arXiv:2005.01643*.
5. Pomerleau (1991). Efficient Training of Artificial Neural Networks for Autonomous Navigation. *Neural Computation*.
6. Sutton & Barto (2018). *Reinforcement Learning: An Introduction* (2nd ed.). Chapter 13.