

策略梯度 (Policy Gradient / REINFORCE)

先讲一个故事

DQN 之后，我们已经能让 AI 在 Atari 游戏上打败人类。但有人提出了一个问题：DQN 的本质是「找到每个状态下最好的动作」——这套逻辑在动作是离散的时候很好用，但如果要控制一只机械手臂呢？

机械手臂的每个关节角度是连续值，动作空间无限大，根本列不出一张 Q 表，也没法对所有动作取最大值。而且更根本的问题是：DQN 学的是「哪个动作最好」(Q 函数)，它绕了一圈，并没有直接告诉你「应该用什么策略」。

有没有一种更直接的方式——直接优化策略本身？

这就是 **策略梯度 (Policy Gradient)** 的出发点：不学 Q 值，改学一个参数化的策略 $\pi(a | s; \theta)$ ，通过梯度上升让它越来越好。REINFORCE 是这条路上最原始也最重要的算法。

本章的核心问题：怎么对一个策略求梯度？

从 Q 值到策略

两种 RL 的哲学

- **基于价值 (Value-based)**：先学 $Q(s, a)$ ，再从 Q 值派生出策略（如 ϵ -贪心）。DQN 属于这一类。
- **基于策略 (Policy-based)**：直接参数化策略 π_θ ，最大化期望总回报 $J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta}[R(\tau)]$ 。

策略梯度的优势：

- 天然支持连续动作（输出均值和方差，从高斯分布采样）；
- 策略是随机的 (stochastic)，内置探索，不需要额外的 ϵ -贪心；
- 优化目标平滑，收敛性有一定理论保证。

问题： $J(\theta)$ 对 θ 的梯度怎么算？

期望总回报是一个轨迹上的期望，而轨迹的分布又依赖 θ ——对一个依赖参数的期望求梯度，不能直接交换梯度和期望符号。

对数导数技巧 (Log-Derivative Trick)

关键恒等式：

$$\nabla_\theta \pi_\theta(a | s) = \pi_\theta(a | s) \cdot \nabla_\theta \log \pi_\theta(a | s)$$

利用这个技巧，可以把对分布的梯度转化为期望内部的梯度：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^T \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot G_t \right]$$

其中 $G_t = \sum_{k=t}^T \gamma^{k-t} r_k$ 是从第 t 步开始的折扣回报。

直觉：这个梯度的含义很漂亮—— G_t 大（这条路走得好），就增大 $\log \pi(a_t | s_t)$ （让这个动作更可能发生）； G_t 小，就降低它的概率。**好的行为得到强化，坏的行为被压制。**

REINFORCE 算法

策略梯度定理告诉我们梯度的形式，但期望无法精确计算——用 Monte Carlo 采样估计它：

1. 用当前策略 π_θ 完整地跑一个 episode，收集轨迹 $\{(s_t, a_t, r_t)\}$ ；
2. 计算每步的折扣回报 G_t （从轨迹末尾反向累加）；
3. 用梯度估计更新参数：

$$\theta \leftarrow \theta + \alpha \sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot G_t$$

这就是 **REINFORCE** 算法 (Williams, 1992)。完整跑一个 episode 才做一次更新，用回报 G_t 作为「信号强弱」来缩放梯度——简洁优雅，但有一个致命弱点。

高方差：REINFORCE 的软肋

Monte Carlo 估计有无偏性（无数次采样的均值等于真实期望），但方差极大：

- 同一个状态 s ，不同 episode 下的回报 G_t 可能从 10 到 500 都有；
- 策略更新完全依赖单条轨迹的运气——运气好就大幅强化，运气差就大幅抑制；
- 学习曲线剧烈抖动，有时突然冲高，又迅速掉回来，难以稳定收敛。

实验如图 1 所示：5 个随机种子的原始训练曲线波动巨大，平滑均值始终维持在低水平，vanilla REINFORCE 在 500 集内无法稳定解决 CartPole-v1。

方差缩减：Value Baseline

核心思路

方差大的根源： G_t 这个数字本身就很大（CartPole 满分 500），用它直接缩放梯度，导致更新步长飘忽不定。

解决思路：不用 G_t ，改用「这次比平均水平好多少」——即**优势函数 (Advantage)**：

$$A_t = G_t - V(s_t)$$

其中 $V(s_t)$ 是对当前状态期望回报的估计 (Baseline)。减去均值后， A_t 在 0 附近波动，方差大幅降低。

为什么减去 Baseline 不影响梯度方向？

可以证明，任何只依赖状态（不依赖动作）的函数 $b(s)$ 满足：

$$\mathbb{E}_{\tau \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(a_t | s_t) \cdot b(s_t)] = 0$$

因此减去 $V(s_t)$ 不改变梯度的期望，只降低方差——是一个方差缩减 (variance reduction) 技巧，在统计学中称为控制变量法。




图 1: Vanilla REINFORCE 的高方差 (CartPole-v1, 5 个随机种子)。原始轨迹剧烈波动, 部分 episode 短暂冲高但随即回落, 平滑均值长期维持在较低水平。

实践: 用神经网络估计 $V(s)$

在实际的 REINFORCE with Baseline 中:

- 额外维护一个 **Value Network** $V(s; \phi)$, 通过最小化均方误差 $\mathcal{L}(\phi) = \mathbb{E}[(G_t - V(s_t; \phi))^2]$ 来训练;
- Policy 梯度改为 $\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot A_t$;
- $V(s)$ 的学习率与容量要克制——它要回归的是**期望**回报 $v^{\pi}(s)$; 若网络把访问过的每条轨迹的**已实现** G_t 都记住 (过拟合), 训练数据上 $A_t \approx 0$, policy 的梯度信号消失。

与第 6 章的关系: 这里的「学习率更低」针对 MC 回归下的记忆化风险; 第 6 章的 Actor-Critic 采用 bootstrapping, 两时间尺度理论要求 Critic 反而学得**更快**——场景不同, 两条结论并不矛盾。消融实验如图 2 所示。

策略熵: 从随机到确定

策略熵定义为:

$$H(\pi(\cdot | s)) = - \sum_a \pi(a | s) \log \pi(a | s)$$

对于 CartPole 的二动作环境, 均匀随机策略的熵最大为 $\ln 2 \approx 0.693$ nats。熵下降, 意味着策略从「乱按按键」走向「确定选择」。

图 3 展示了两种方法在训练过程中的熵演化:




图 2: 有 / 无 Value Baseline 的训练对比 (CartPole-v1, 5 个随机种子, 阴影为 $\pm 1\sigma$)。加入 Baseline 后, 部分种子能在 500 集内收敛到接近满分, 整体期望回报显著高于 Vanilla REINFORCE。




图 3: 策略熵在训练过程中的演化 (CartPole-v1, 5 个随机种子, 阴影为 $\pm 1\sigma$)。Vanilla REINFORCE 熵迅速塌缩至接近 0, 但并未收敛到好策略, 是过早陷入坏的确定性策略; 有 Baseline 的版本熵下降更平缓, 保留探索能力, 最终收敛到更好的策略。

两条曲线对比揭示了一个有趣的现象：熵快速下降并不代表「学得好」——Vanilla REINFORCE 的熵在约 100 集后几乎归零，但对应的 return 仍然很低（图 1）。策略过早收敛到一个糟糕的确定性行为（比如始终向一个方向推），探索能力丧失，无法继续改进。Value Baseline 通过提供更稳定的学习信号，让策略得以持续探索，才有机会发现更优的行为模式。

完整算法：REINFORCE with Value Baseline

1. **初始化**：Policy Network $\pi(a | s; \theta)$, Value Network $V(s; \phi)$;
2. **每个 episode**:
 - (a) 用 π_θ 跑完整一集，收集 $\{(s_t, a_t, r_t)\}_{t=0}^T$;
 - (b) 反向计算折扣回报： $G_t = \sum_{k=t}^T \gamma^{k-t} r_k$;
 - (c) 更新 Value Network： $\phi \leftarrow \phi - \alpha_V \nabla_\phi \sum_t (G_t - V(s_t; \phi))^2$;
 - (d) 计算优势： $A_t = G_t - V(s_t; \phi)$ (detach, 不回传梯度);
 - (e) 更新 Policy Network： $\theta \leftarrow \theta + \alpha_\pi \sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot A_t$ 。

关键超参数注意事项：

设置	原因
$\alpha_V < \alpha_\pi$	$V(s)$ $A_t \approx 0$
不对 A_t 做 z-score	$V(s)$
clip_grad_norm	

Policy Gradient 在 RL 体系中的位置

REINFORCE 是策略梯度方法的起点，承接经典 RL，开启 Actor-Critic 主线：

1. **从价值到策略**：Q-learning / DQN 优化 Q 函数，间接得到策略；Policy Gradient 直接优化 π_θ ，目标更清晰，天然支持连续动作空间；
2. **Monte Carlo 的代价**：REINFORCE 等整集结束才更新，数据效率低，方差大；这催生了下一步的改进；
3. **Actor-Critic (A2C/A3C)**：把 REINFORCE 中的 Monte Carlo 回报 G_t 换成 TD 估计 (Bootstrapping)，不等 episode 结束就更新。Actor (Policy) 和 Critic (Value) 协同训练，方差和偏差均衡；
4. **PPO / TRPO**：在 Actor-Critic 基础上加入策略更新幅度约束，防止一步更新破坏策略；PPO 是目前工业界最广泛使用的策略梯度算法，ChatGPT 的 RLHF 训练正是基于它；
5. **连续控制主线**：DDPG、TD3、SAC 把策略梯度扩展到连续动作空间，成为机器人控制的主流方法。

参考资料

1. Williams, R. J. (1992). Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8, 229–256.
2. Sutton, R. S. & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). Chapter 13: Policy Gradient Methods.
3. Schulman, J., et al. (2015). Trust Region Policy Optimization. *ICML*.
4. Schulman, J., et al. (2017). Proximal Policy Optimization Algorithms. *arXiv:1707.06347*.
5. 动手学强化学习 (Hands-on-RL) . 第 9 章: 策略梯度算法.