

从偏好到奖励 (RLHF / Reinforcement Learning from Human Feedback)

先讲一个故事

你想让一个语言模型「回答得更好」。好，意味着准确、克制、有帮助、不胡编——你试着把这些写成一个奖励函数，很快就会放弃：这些标准既写不全，也写不准。

错误做法 / 朴素做法：手工设计打分规则——回答越长加分、出现礼貌用语加分、命中关键词加分。模型会立刻学会刷规则：无限拉长回答、堆砌客套话，分数很高，回答很差。

本章方法的做法：不定义「好」，而是让人**比较**——同一个问题的两个回答，哪个更好？从大量成对比较中学出一个**奖励模型**，再用强化学习（第 7 章的 PPO）去优化它。

本章的核心问题：学出来的奖励只是真实偏好的**代理**，它能被优化多远而不被击穿？

$$\max_{\pi} \mathbb{E}_{y \sim \pi} [r_{\varphi}(y)] - \beta \text{KL}(\pi \parallel \pi_{\text{ref}})$$

数学形式化

偏好数据是成对比较：给定两个候选 y_a, y_b ，标注者选出更好的一个。Bradley-Terry 模型假设比较概率由潜在奖励之差决定：

$$P(y_a \succ y_b) = \sigma(r_{\varphi}(y_a) - r_{\varphi}(y_b))$$

- r_{φ} —— 奖励模型，从偏好对中学习，是真实偏好的代理；
- π_{ref} —— 参考策略（通常是 SFT 模型），偏好数据从它的样本中采集；
- β —— KL 锚定系数，控制策略离参考策略多远；
- σ —— sigmoid 函数，把奖励差映射为比较概率。

奖励从哪里来：偏好建模

Bradley-Terry 负对数似然

给定偏好对集合 $\{(y_w, y_l)\}$ (y_w 胜、 y_l 负)，奖励模型通过最小化负对数似然学习：

$$\mathcal{L}(\varphi) = -\mathbb{E}_{(y_w, y_l)} [\log \sigma(r_{\varphi}(y_w) - r_{\varphi}(y_l))]$$

注意 BT 模型只由**奖励差**决定：给 r_{φ} 整体加一个常数、乘一个尺度，似然不变。因此奖励的绝对数值没有意义，实践中先在参考分布上做**白化**（减均值、除标准差）再交给 RL——这也让 β 在不同种子、不同任务间可迁移。

奖励只在数据覆盖区内可信

偏好对从参考策略的样本中采集，奖励模型因此只在**参考策略的样本分布**上被约束过。覆盖区之外它照样输出数值——但那是网络归纳偏置的外推，不是学到的知识：ReLU 网络在训练支撑集外按分段线性规律**线性外推**，会把「适量有益」外推成「越多越好」。

这与第 9 章离线强化学习的处境完全同构：价值函数（那里是 Q ，这里是 r_φ ）在数据支撑外的估计没有依据，一旦有一个优化器专门去寻找高估的方向，错误就会被无限放大。

实验用一个完全合成的序列任务把这件事摆到明面上：真实质量等于 token 价值均值加上「强调 token」的凹形加分——每个加 0.3 分，超过 3 个后每个倒扣 0.6 分；参考策略几乎不产生超过 3 个强调 token 的序列，偏好数据只覆盖加分的上升段。图 1 左侧显示验证集偏好精度随数据量稳定上升（0.82 $\rightarrow$ 0.86）；右侧显示覆盖区内奖励模型与真实分数一致，覆盖区外真实分数见顶崩坏、奖励模型继续单调上扬。




图 1: 奖励模型的可信边界（玩具序列任务，3 个随机种子，阴影为 $\pm 1\sigma$ ）。左：验证集偏好精度随偏好对数量上升；右：偏好数据覆盖区（灰色， $c_E \leq 3$ ）内奖励模型与真实分数一致，覆盖区外真实分数在 $c_E = 3$ 见顶后崩坏，而奖励模型继续单调外推——分叉处就是 reward hacking 的入口。

核心机制

机制一：Reward hacking——优化器专找分叉

Goodhart 定律：当一个度量成为优化目标，它就不再是好度量。PPO 不知道什么是「真实质量」，它只会沿代理奖励最陡的方向爬——而奖励模型给出的最陡方向，恰恰通向它自己没有依据的外推区。

图 2 是 $\beta = 0$ （无 KL 锚定）的完整轨迹：约前 30 轮是**真实提升**（真实分数从 +0.39 升到约 +1.0，策略把强调 token 用到甜点区附近）；随后优化冲出数据覆盖区，把强调 token 打满——代理奖励继续上涨到 +7 以上，真实分数崩塌到 -4.5。代理指标一路向好、真实目标一路崩坏，与第 9 章「Q 涨、回报跌」是同一张图的两个化身。

机制二：KL 锚定——把优化关在可信区附近

解药不是修好奖励模型（它在覆盖区外注定不可信），而是不让策略走出覆盖区太远。在目标中加入对参考策略的 KL 惩罚：

$$J(\pi) = \mathbb{E}_{y \sim \pi} [r_\varphi(y)] - \beta \text{KL}(\pi \parallel \pi_{\text{ref}})$$

KL 项把策略拴在参考策略的邻域内，而奖励模型恰好在这个邻域内被数据约束过——两者的「可信区」是同一个区域，这不是巧合，而是 KL 锚定有效的根本原因。




图 2: $\beta = 0$ 时的 reward hacking (3 个随机种子, 阴影为 $\pm 1\sigma$)。约前 30 轮为真实提升 (真实分数 $+0.39 \rightarrow$ 约 $+1.0$)；随后策略冲出偏好数据覆盖区, 代理奖励 (左轴) 继续上涨到 $+7$ 以上, 真实分数 (右轴) 崩塌到 -4.5 。

β 是一个真正的权衡超参。图 3 给出三种结局: $\beta = 0$ 崩塌; $\beta = 0.5$ 把最终 KL 压在约 2 nats, 真实分数稳定在约 $+0.84$ 的真提升区; $\beta = 2.0$ 锚定过强, 策略几乎钉在 SFT 水平 (约 $+0.53$), 浪费了偏好信息。

机制三：奖励白化——让 β 有稳定的量纲

BT 似然对奖励的平移和缩放不变, 不同训练得到的奖励模型天然处在不同尺度上。若直接把原始分数交给 RL, 同一个 β 在不同种子间的实际约束强度会相差数倍。在参考分布上白化 ($\tilde{r} = (r - \mu_{\text{ref}})/\sigma_{\text{ref}}$) 后, 「奖励一个标准差」与「KL 一个 nat」之间的兑换率才是稳定的。

完整算法流程

RLHF 四步

1. **SFT**: 在示范数据上监督微调, 得到参考策略 π_{ref} ;
2. **偏好收集**: 从 π_{ref} 采样成对候选, 由标注者比较;
3. **奖励建模**: 用 BT 负对数似然训练 r_{φ} , 在参考分布上白化;
4. **RL 微调**: 用 PPO 最大化 $\tilde{r}_{\varphi} - \beta \text{KL}$, 必要时回到第 2 步用新策略的样本迭代扩充偏好数据。

Fig 3. KL anchoring (3 seeds, mean $\pm$ std)




图 3: KL 锚定的三种结局 (3 个随机种子, 阴影为 $\pm 1\sigma$, 虚线为 SFT 基线 +0.39)。 $\beta = 0$ 崩塌到 -4.5 ; $\beta = 0.5$ 稳定在约 $+0.84$ (最终 KL 约 2 nats); $\beta = 2.0$ 锚定过强, 几乎钉在 SFT 水平 (约 $+0.53$)。

与相邻方法对比

RLHF vs SFT, 以及与离线 RL 的同构

- **SFT** 模仿数据的平均行为, 无法超过示范水平; **RLHF** 沿偏好方向优化, 可以超过示范——代价是引入可被击穿的代理奖励;
- **与离线 RL 同构**: 第 9 章里 $\max$ 算子放大 Q 在数据外的高估, 本章里 PPO 放大 r_φ 在覆盖区外的外推——同一个病 (数据支撑外的乐观估计被优化器放大), CQL/IQL 把悲观写进价值或动作集合, RLHF 把约束写进 KL 项。

本章在 RL 体系中的位置

1. 上游: PPO (第 7 章) 提供优化引擎; 离线强化学习 (第 9 章) 提供「外推误差被优化放大」的病理模型;
2. 从偏好到奖励 (RLHF) (本章: 当奖励本身也要学习时, 优化的边界由数据覆盖决定);
3. 下游: DPO 绕开显式奖励模型, 把偏好直接写进策略目标; GRPO 与可验证奖励 (RLVR) 用规则奖励替代学习奖励, 消除被击穿的可能。

读者应带走一句话: 学出来的奖励是一张有边界的地图, RL 是一辆没有刹车的车——KL 锚定不是让地图变准, 而是不让车开出地图。下一章从 DPO 开始, 看如何不画这张地图。

参考资料

1. Christiano et al. (2017). Deep Reinforcement Learning from Human Preferences. *NeurIPS*.
2. Ziegler et al. (2019). Fine-Tuning Language Models from Human Preferences. *arXiv:1909.08593*.
3. Stiennon et al. (2020). Learning to Summarize with Human Feedback. *NeurIPS*.
4. Ouyang et al. (2022). Training Language Models to Follow Instructions with Human Feedback. *NeurIPS*.
5. Gao, Schulman & Hilton (2023). Scaling Laws for Reward Model Overoptimization. *ICML*.