

时序差分学习 (Temporal Difference Learning, TD)

先讲一个故事

你每天走同一条路去学校。今天走到一半发现路被封了，绕路后比平时多花了 10 分钟。下次你该怎么预测到校时间？

- **方法 A**：走完整条路，到家看钟，用实际时间更新预测。准确，但必须等走完；
- **方法 B**：走到一半，看一眼剩下一半的路况，猜今天大概要多久，当场修正预测。不用等走完，但猜的那部分可能有偏差。

方法 A 是蒙特卡洛 (MC)，方法 B 就是**时序差分学习 (TD)**。TD 的核心想法：**不用等到结局**，每走一步就用「即时反馈 + 对未来的猜测」修正当前估计——你不需要完整的真相，只需要一步的反馈和当前的预测。

数学形式化：TD(0) 更新法则

回顾两个极端：

蒙特卡洛 (MC) ——跑完整条轨迹，用真实回报更新：

$$V(S_t) \leftarrow V(S_t) + \alpha [G_t - V(S_t)], \quad G_t = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{T-t-1} R_T$$

G_t 是 $v_\pi(S_t)$ 的无偏估计，但方差大（一条轨迹波动大），且必须等 episode 结束。

动态规划 (DP) ——用已知模型对所有后继状态求期望：

$$V(s) \leftarrow \sum_a \pi(a | s) \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s') \right]$$

零方差、确定性，但需要完整的环境模型 $P(s' | s, a)$ ，现实中通常没有。

TD(0) 取两者的优点——每步用一步**真实奖励**和**对后继的当前估计**：

$$V(S_t) \leftarrow V(S_t) + \alpha \left[\underbrace{R_{t+1} + \gamma V(S_{t+1})}_{\text{TD 目标}} - V(S_t) \right]$$

- $R_{t+1} + \gamma V(S_{t+1})$ ——**TD 目标 (TD target)**：用一步真实奖励 + 对后继状态的当前估计近似 G_t ；
- $R_{t+1} + \gamma V(S_{t+1}) - V(S_t)$ ——**TD 误差 (TD error)**：当前估计与更「新鲜」估计之间的差距；
- 和 MC 的区别：MC 用真实 G_t ，TD 用估计 $V(S_{t+1})$ 替代 $t+1$ 之后未知的奖励——这就是 **Bootstrapping**（用估计值更新估计值）；
- 和 DP 的区别：DP 对所有后继求期望需要 $P(s' | s, a)$ ，TD 只**采样了一次实际的** S_{t+1} ——TD 不需要模型。

TD 误差与「学得快」的来源

TD 误差的严格定义

设时刻 t 智能体在 S_t ，执行动作后得到 R_{t+1} 、转移到 S_{t+1} 。TD 误差定义为：

$$\delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t)$$

如果 $V = v_\pi$ (真实价值函数), 则 $\mathbb{E}[\delta_t | S_t = s] = 0$ ——这是 Bellman 方程的直接推论: $v_\pi(s) = \mathbb{E}_\pi[R_{t+1} + \gamma v_\pi(S_{t+1}) | S_t = s]$ 。当 V 逼近 v_π 时, δ_t 趋近零均值。TD 学习就是不断把 δ_t 驱向零的过程。

MC vs TD(0): 偏差-方差权衡

	MC	TD(0)
更新目标	G_t (真实回报)	$R_{t+1} + \gamma V(S_{t+1})$ (一步估计)
Bootstrapping	否	是
偏差	无偏	有偏
方差	高	低
需等 episode 结束	是	否
需模型	否	否

TD 引入**有偏估计**, 换来了**方差大幅降低**与更快收敛。在 5 状态随机游走上 (图 1), 用同一批轨迹观察两种方法的估计质量: MC 必须用较小的步长 ($\alpha = 0.01$) 来平均回报、估计粗糙且滞后; TD(0) 用更大的步长 ($\alpha = 0.1$) 每步就地修正, 更快贴近真实价值。




图 1: 5 状态随机游走的价值估计 (同一批轨迹)。黑线为真实价值 $v(s) = s/6$, 红色为 MC ($\alpha = 0.01$), 蓝色为 TD(0) ($\alpha = 0.1$)。TD(0) 在 100、200 局后都更贴近真实值 (100 局平均 RMS: MC 0.149 vs TD 0.062)。

从预测到控制: SARSA 与 Q-Learning

上一节用 V 讲预测; 本节用 Q 讲控制 (学策略)。

on-policy: SARSA

SARSA 的目标是学习「当前实际执行的策略」(含探索) 的 q_π :

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$$

动作选择通常用 ϵ -贪心。SARSA 的更新逻辑:

1. 在 S_t 按 ε -贪心选 A_t ;
2. 执行 A_t , 得到 R_{t+1} , 到达 S_{t+1} ;
3. 在 S_{t+1} 按 ε -贪心再选 A_{t+1} (不执行, 只用它的 Q 值);
4. 用 A_{t+1} 的 Q 值更新 $Q(S_t, A_t)$;
5. $S_t \leftarrow S_{t+1}$, $A_t \leftarrow A_{t+1}$, 重复。

关键: 目标中的 A_{t+1} 来自**实际执行的策略** (含探索), 因此 SARSA 学到的是 ε -贪心策略下的 q_π , **考虑到了探索的代价**。

off-policy: Q-Learning

Q-Learning 学习**最优** (贪心) 策略, 但执行时仍用探索策略:

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t)]$$

和 SARSA 的唯一区别: 目标中用了 $\max_a Q(S_{t+1}, a)$ 而不是 $Q(S_{t+1}, A_{t+1})$ 。SARSA 的目标取决于实际选的动作 A_{t+1} (含探索噪音); Q-Learning 的目标**总是假设下一步选最优动作**, 无论实际探索做了什么。这就是 off-policy: **学习的策略** (贪心 = 最优) 与**执行的策略** (ε -贪心 = 探索) 不同。

SARSA vs Q-Learning: 悬崖行走

经典的 Cliff Walking 环境 (4×12 格子, 起点左下、目标右下, 底部一行中间 10 格是悬崖: 踩中回到起点并罚 -100 , 普通步罚 -1) 揭示了两种算法的本质差异, 如图 2 所示。

关键洞察: Q-Learning 假设「下一步及以后都是最优的」, 所以它认为贴崖走没问题 (最优策略不会踩); SARSA 知道实际执行时偶尔会探索, 贴着悬崖走一次随机探索就是大灾难, 因此学到更保守但安全的策略。如果部署时完全贪心 ($\varepsilon = 0$), Q-Learning 的激进策略可能更优——取决于你的 agent 在部署时还会不会犯错。

Expected SARSA 与 Softmax 策略

Expected SARSA 不采样 A_{t+1} , 而是对所有动作求期望, 消除采样方差:

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \sum_a \pi(a | S_{t+1}) Q(S_{t+1}, a) - Q(S_t, A_t) \right]$$

当目标策略 π 是 ε -贪心时它是 on-policy; 当 π 是纯贪心时它**等价于 Q-Learning** (off-policy)。绝大多数任务上 Expected SARSA 优于传统 SARSA——微小的计算开销增加被方差下降带来的样本效率提升远远补偿。

Softmax 策略 用温度 τ 按 Q 值的相对大小分配探索概率:

$$\pi(a | s) = \frac{\exp(Q(s, a)/\tau)}{\sum_b \exp(Q(s, b)/\tau)}$$

τ 大趋于均匀探索, $\tau \rightarrow 0$ 趋于纯贪心。探索不再是盲目的 (ε -贪心以 ε 的概率随机探索, 每个非贪心动作各以 $\varepsilon/|\mathcal{A}|$ 的概率被选中, 包括明显差的), 而是**更好的动作获得更多的选择概率**。




图 2: 悬崖行走 (4×12 , $\alpha = 0.5$, $\varepsilon = 0.1$, $\gamma = 1$, 20 个随机种子, 10 局滑动平均)。训练期间 SARSA 的每局累计奖励显著高于 Q-Learning: SARSA 学到保守安全的绕行路线 (偶尔探索也不至于灾难性坠崖), Q-Learning 学最短路径、但训练时因随机探索频繁坠崖。

多步扩展: N 步 TD 与 TD(λ)

N 步回报

TD(0) 只看一步 (低方差高偏差), MC 看全程 (无偏高方差)。**N 步 TD** 是两者之间的连续谱, 定义 n 步回报:

$$G_t^{(n)} = R_{t+1} + \gamma R_{t+2} + \cdots + \gamma^{n-1} R_{t+n} + \gamma^n V(S_{t+n})$$

- $n = 1$: $G_t^{(1)} = R_{t+1} + \gamma V(S_{t+1})$ —— TD(0);
- $n \rightarrow \infty$: $G_t^{(\infty)} = G_t$ —— MC;
- $1 < n < \infty$: n 个真实奖励 + 在第 n 步截断处用 V 估计余下部分。

更新式: $V(S_t) \leftarrow V(S_t) + \alpha [G_t^{(n)} - V(S_t)]$ 。N 步 SARSA 同理, 只需把 V 换成 Q , 最后一项用 $\sum_a \pi(a | S_{t+n}) Q(S_{t+n}, a)$ 即为 Expected n-step SARSA。

图 3 展示了 n 对偏差-方差权衡的影响: n 越小 (越依赖 bootstrapping) 误差越低, n 越大 (越依赖真实奖励) 越接近 MC 的高误差。

TD(λ)

与其只用一个 n , TD(λ) 把所有 n 步回报用几何加权平均混合:




图 3: 5 状态随机游走上 N 步 TD 的 RMS 误差随局数的变化 (同一 $\alpha = 0.1$, 平均 100 局)。 $n = 1$ (TD(0)) 误差最低, $n = 3$ 、 $n = 10$ 依次上升, $n \rightarrow \infty$ (MC) 误差最高—— n 越小、bootstrap 越多, 方差越小、学得越快。

$$G_t^\lambda = (1 - \lambda) \sum_{n=1}^{\infty} \lambda^{n-1} G_t^{(n)}$$

- $\lambda = 0$: $G_t^\lambda = G_t^{(1)}$ —— TD(0);
- $\lambda = 1$: $G_t^\lambda = G_t$ —— MC;
- $0 < \lambda < 1$: 越近的步伐权重越大, 越远的路贡献越小但非零。

λ 控制 bootstrap 的程度: 越小越依赖估计值 (高偏差低方差), 越大越依赖真实奖励 (低偏差高方差)。

资格迹: TD(λ) 的在线实现

TD(λ) 需要等到 episode 结束才能计算 G_t^λ (需要所有 n 步回报)。**资格迹** (Eligibility Traces) 提供在线增量式实现: 每访问一个状态-动作对 (s, a) , 给它的资格迹加 1, 此后每步所有资格迹按 $\gamma\lambda$ 衰减:

$$e_t(s, a) = \begin{cases} \gamma\lambda e_{t-1}(s, a) + 1, & \text{如果}(s, a) \text{ 是当前对,} \\ \gamma\lambda e_{t-1}(s, a), & \text{否则.} \end{cases}$$

更新式: 每一步对所有 (s, a) 执行 $Q(s, a) \leftarrow Q(s, a) + \alpha \delta_t e(s, a)$ 。直觉: 资格迹是「这个状态-动作对在多大程度上为当前结果负责」的衰减记录——越近的对权重越大, 久远的对逐渐衰减归零。

Watkins' Q(λ): 资格迹天然 on-policy, Q-Learning 是 off-policy 的, 需要特殊处理——一旦执行了非贪心动作 (探索), 未来轨迹不再遵循目标策略, 资格迹必须清零:

$$\text{若 } A_{t+1} \neq \arg \max_a Q(S_{t+1}, a) \implies \text{所有 } e(s, a) \leftarrow 0$$

代价: 探索率高时, 资格迹的有效长度取决于「连续贪心动作的长度」而非固定的 λ 。

经验回放——off-policy 的数据复用

在线学习每步只用当前转移 ($S_t, A_t, R_{t+1}, S_{t+1}$) 更新一次就丢弃, 数据利用率极低。**经验回放** (Experience Replay) 维护一个固定大小的缓冲, 存储最近 N 条转移:

1. 执行策略产生新转移, 存入缓冲;
2. 从缓冲中**随机采样**一个 mini-batch;
3. 在采样转移上做多次 Q-Learning 更新。

为什么有效?

- **打破相关性**: 连续步的转移高度相关, 随机采样打乱顺序, 降低更新方差;
- **样本复用**: 每条转移被多次使用, 提高数据效率;
- **稳定训练**: 相当于用了一组「旧数据」做正则化。

限制: 经验回放只能用于 off-policy 算法 (Q-Learning、Expected SARSA)。SARSA 不能用——它的更新依赖当前策略下的动作选择, 而缓冲里的旧数据来自旧策略, 不匹配。

本章在 RL 体系中的位置

1. **上游**: MAB 的增量更新与探索-利用权衡、MDP 的 Bellman 方程与 DP 三种精确求解。DP 需要已知模型、MC 用真实回报 (无偏高方差、需等回合结束), TD 取两者之长——一步采样 + bootstrap;
2. **本章 (TD 学习)**: 不依赖模型的价值学习核心——TD(0) 的一步更新、SARSA/Q-Learning 的 on/off-policy 分野、 N 步与资格迹在偏差-方差之间调节、经验回放提升 off-policy 数据效率;
3. **下游**: Q-Learning 的 max 算子 + 神经网络函数逼近 = DQN; 经验回放 + 目标网络驯服 TD 更新的不稳定性 (下一章)。

TD 学习算法族谱

算法	on/off-policy	Bootstrap	目标形式	特点
MC	on	否	G_t	无偏, 高方差
TD(0)	on	是	$R + \gamma V(s')$	有偏, 低方差
SARSA	on	是	$R + \gamma Q(s', a')$	考虑探索代价
Q-Learning	off	是	$R + \gamma \max_a Q(s', \cdot)$	学最优策略
Expected SARSA	均可	是	$R + \gamma \sum_a \pi(a s') Q(s', a)$	低方差
N-step	均可	是	n 步混合回报	偏差-方差可调
$Q(\lambda)$	off	是	λ -加权回报 + 资格迹	在线多步

- **TD(0)**: 一步真实奖励 + 下一步估计, 无需等 episode 结束;
- **SARSA**: 做什么就学什么, ϵ -贪心下的真实 q_π , 保守安全;
- **Q-Learning**: 直接学最优策略的 q_* , 不管实际如何探索;
- **Expected SARSA**: 对采样求平均, 降低方差, 可退化为 Q-Learning;
- **N-step TD**: 折中偏差和方差, 越大的 n 越接近 MC;
- **TD(λ) + 资格迹**: 用指数衰减对每步误差分配功劳, 在线实现多步传播;
- **经验回放**: 存旧数据、随机重放, 打破相关性、提升样本效率 (仅 off-policy 可用)。

从 TD 到 DQN 的桥梁

1. **Q-Learning 的 max 算子 + 函数逼近** = DQN (Deep Q-Network);
2. **经验回放 + 目标网络** = 解决 DQN 中 TD 更新的不稳定性;
3. **ϵ -贪心探索**被延续到 DQN 中 (简单但有效, 后来被 NoisyNet 等方法改进);
4. **资格迹**的思想 $\rightarrow$ Retrace 算法 $\rightarrow$ 结合经验回放实现高效 off-policy 多步学习。

学完本章, 你掌握了「不依赖模型」的价值学习核心——TD 用 bootstrapping 换方差、SARSA/Q-Learning 区分 on/off-policy、 N 步与资格迹在偏差-方差之间调节。下一章 DQN 把 Q-Learning 的表格换成神经网络, 并用经验回放与目标网络驯服它的不稳定性。

参考资料

1. Sutton & Barto (2018). *Reinforcement Learning: An Introduction* (2nd ed.). Chapters 6–7, 12.
2. Watkins, C. J. C. H. (1989). *Learning from Delayed Rewards*. PhD Thesis. (Q-Learning 原始论文)
3. Rummery & Niranjan (1994). On-line Q-learning using connectionist systems. (SARSA 原始论文)
4. van Seijen et al. (2009). A theoretical and empirical analysis of Expected Sarsa.

5. Lin (1992). Self-improving reactive agents based on reinforcement learning. (Experience Replay 的发明)
6. Mnih et al. (2015). Human-level control through deep reinforcement learning. *Nature*. (DQN + Experience Replay)
7. Practical RL, Yandex Data School. Week 3——Model-Free Reinforcement Learning.